SPRAWOZDANIE

Zajęcia: Nauka o danych I

Prowadzący: prof. dr hab. Vasyl Martsenyuk

Laboratorium Nr 6 Data 07.12.2024 Temat: „Analiza danych z wykorzystaniem narzędzi do modelowania regresji” Wariant 11	Szymon Nycz Informatyka II stopień, niestacjonarne, 1 semestr, gr.1b

1. Polecenie:

   Premise General Population COVID-19 Health Services Disruption Survey 2020
   http://ghdx.healthdata.org/record/ihme-data/premise-general-population-covid-19-health-services-disruption-survey-2020

   Link do repozytorium:
   https://github.com/Maciek332/Semestr_1_Nycz/tree/master/NoD

2. Opis programu opracowanego

W Pythonie oraz KNIME porównaj wyniki regresji liniowej i Ridge na tym samym zbiorze danych.

- KNIME

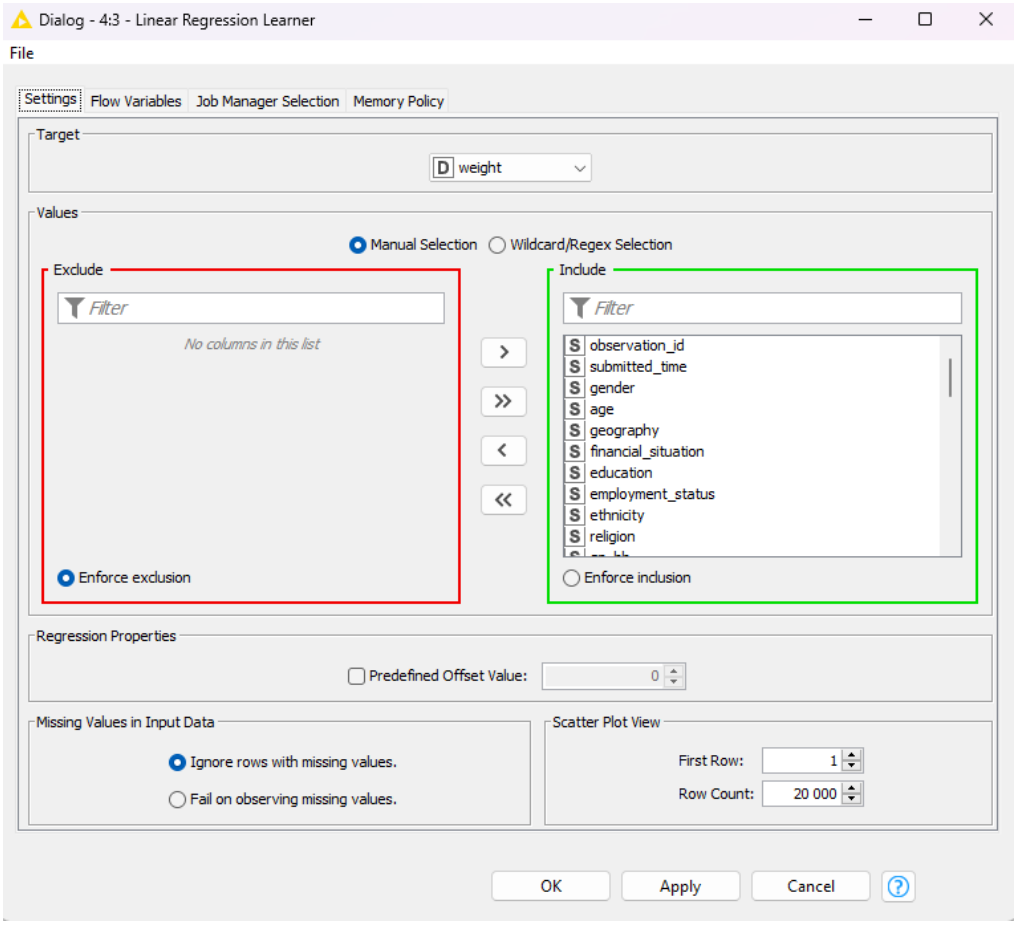

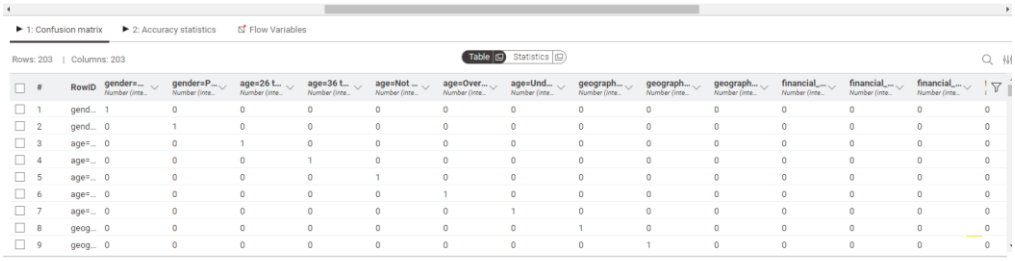

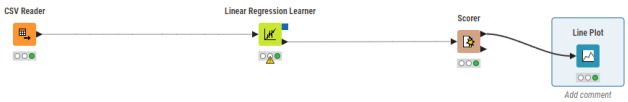

- Python

```
from sklearn.datasets import load_diabetes
from sklearn.linear_model import LinearRegression, Ridge, Lasso
from sklearn.model_selection import train_test_split
from sklearn.metrics import mean_squared_error, r2_score

data = load_diabetes()
X, y = data.data, data.target

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2)

lr = LinearRegression()
lr.fit(X_train, y_train)
y_pred_lr = lr.predict(X_test)
print("R^2:", r2_score(y_test, y_pred_lr))
```

[1] ✓ 2.0s

```
R^2: 0.551421067415138
```

```python
from sklearn.linear_model import Ridge
from sklearn.datasets import load_diabetes

# Załaduj dane
data = load_diabetes()
X, y = data.data, data.target

# Trenuj model Ridge
ridge = Ridge(alpha=1.0)
ridge.fit(X, y)

# Współczynniki regresji jako miara ważności cech
feature_importance = abs(ridge.coef_)
print("Ważność cech:", feature_importance)
```

[2] ✓ 0.0s

```
Ważność cech: [ 29.46611189  83.15427636 306.35268015 201.62773437   5.90961437
  29.51549508 152.04028006 117.3117316  262.94429001 111.87895644]
```

```python
from scipy.stats import shapiro
import matplotlib.pyplot as plt
import numpy as np

# Oblicz reszty
residuals = y - ridge.predict(X)

# Histogram reszt
plt.hist(residuals, bins=20)
plt.title("Histogram reszt")
plt.show()

# Test Shapiro-Wilka
stat, p = shapiro(residuals)
print("Statystyka Shapiro-Wilka:", stat, "P-wartość:", p)
```

3] ✓ 1.3s

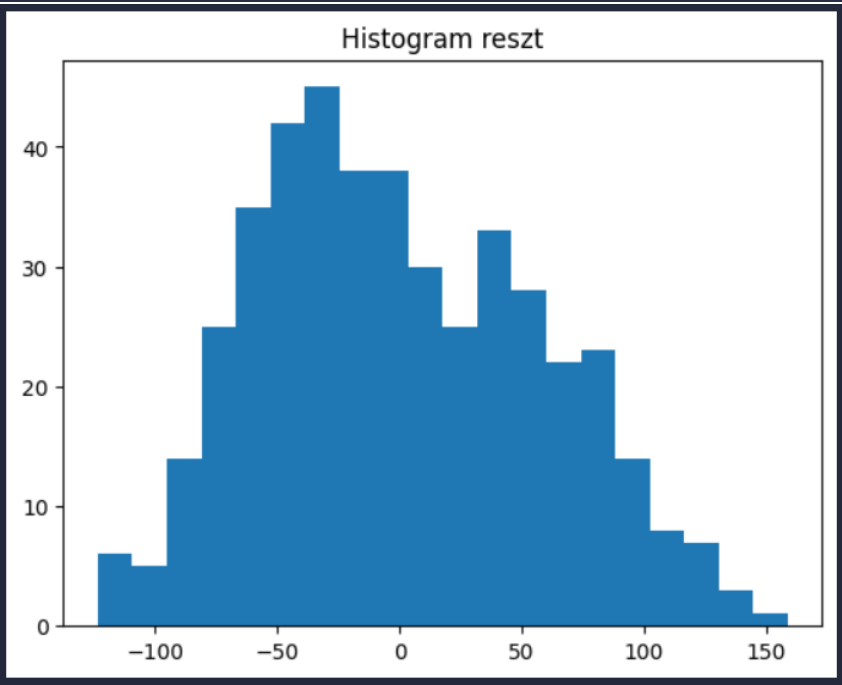


```
Statystyka Shapiro-Wilka: 0.982184886932373 P-wartość: 2.9706814530072734e-05
```

```python
from statsmodels.stats.stattools import durbin_watson

# Test Durbin-Watsona
dw_stat = durbin_watson(residuals)
print("Statystyka Durbin-Watsona:", dw_stat)
```

[4] ✓ 0.8s

```
Statystyka Durbin-Watsona: 1.927616883684219
```

- R

[4]:
```r
data(mtcars)
X <- as.matrix(mtcars[, -1])
y <- mtcars$mpg

model_lm <- lm(mpg ~ ., data = mtcars)
summary(model_lm)

library(glmnet)
ridge <- glmnet(X, y, alpha = 0)
lasso <- glmnet(X, y, alpha = 1)
```

```
Call:
lm(formula = mpg ~ ., data = mtcars)

Residuals:
    Min      1Q  Median      3Q     Max 
-3.4506 -1.6044 -0.1196  1.2193  4.6271 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 12.30337   18.71788   0.657   0.5181
cyl         -0.11144    1.04502  -0.107   0.9161
disp         0.01334    0.01786   0.747   0.4635
hp          -0.02148    0.02177  -0.987   0.3350
drat         0.78711    1.63537   0.481   0.6353
wt          -3.71530    1.89441  -1.961   0.0633 .
qsec         0.82104    0.73084   1.123   0.2739
vs           0.31776    2.10451   0.151   0.8814
am           2.52023    2.05665   1.225   0.2340
gear         0.65541    1.49326   0.439   0.6652
carb        -0.19942    0.82875  -0.241   0.8122
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.65 on 21 degrees of freedom
Multiple R-squared:  0.869,     Adjusted R-squared:  0.8066 
F-statistic: 13.93 on 10 and 21 DF,  p-value: 3.793e-07
```

[2]:
```r
# Normalność błędów
model <- lm(mpg ~ ., data = mtcars)
residuals <- residuals(model)

# Histogram reszt
hist(residuals, breaks = 20, main = "Histogram reszt")

# Test Shapiro-Wilka
shapiro.test(residuals)
```

```
        Shapiro-Wilk normality test

data:  residuals
W = 0.95694, p-value = 0.2261
```

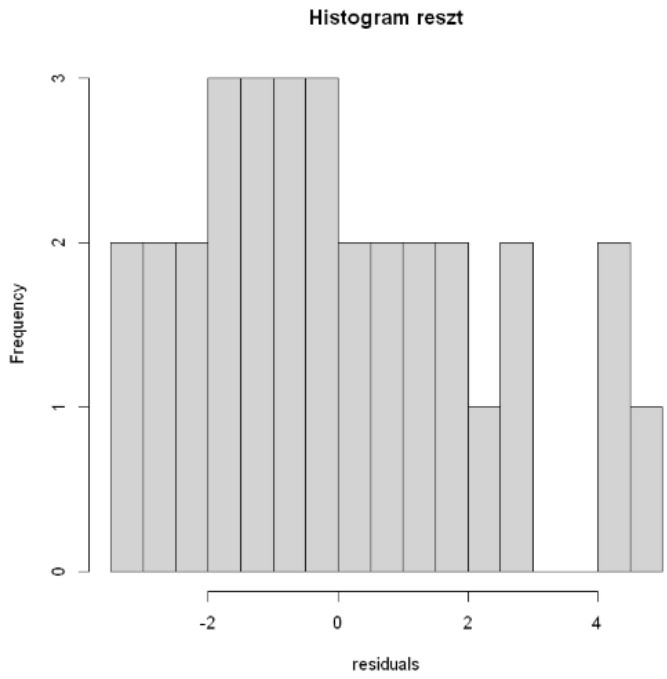


```r
# Autokorelacja reszt
library(lmtest)
dwtest(model)
```

```
        Durbin-Watson test

data:  model
DW = 1.8609, p-value = 0.1574
alternative hypothesis: true autocorrelation is greater than 0
```

3. Wnioski

Regresja liniowa modeluje zależność zmiennej zależnej yy od zmiennych niezależnych x1,x2,…,xpx_1, x_2,…, x_p. W regresji grzbietowej (Ridge) współczynniki βj\beta_j są regularizowane, co pomaga zidentyfikować zmienne o największym wpływie na wyniki modelu. Reszty, czyli różnice między wartościami rzeczywistymi a przewidywanymi, pozwalają ocenić jakość modelu. Regresja z użyciem sieci neuronowych stosuje głębokie uczenie do modelowania skomplikowanych relacji między zmiennymi. W Pythonie można to zrobić z użyciem bibliotek TensorFlow i PyTorch. Wizualizacja struktury sieci neuronowej, na przykład za pomocą plot_model w TensorFlow, jest kluczowa do zrozumienia architektury modelu. Rozmiar partii (batch size) określa liczbę próbek przetwarzanych w jednym cyklu aktualizacji wag, epoka to pełne przejście przez zestaw danych treningowych, a iteracja to pojedyncza aktualizacja wag.